2차 · 데이터 요청서

가상 MMORPG 로그 데이터 제작 요청서

로그 워치독 팀이 데이터 팀에 요청하는 데이터의 **목적, 구조, 양, 유저 구성, 오염 주입, 전달 방식, 검수 기준**을 정리한 문서입니다. 이 문서의 스키마가 두 팀 사이의 데이터 계약이 됩니다.

요청 v0.2 · 2026.10 · 요청: 로그 워치독 팀 · 제작: 데이터 팀 · [ ] 칸은 두 팀이 협의해 채웁니다

한눈에 보기

1. **무엇을:** 가상 MMORPG "○○온라인"의 28일치 유저 활동 로그와 거래 기록, 기준 정보 테이블
2. **얼마나:** 계정 4,000개, 이벤트 약 2,500만~3,500만 건 (권장안). 먼저 1일치 샘플을 받습니다.
3. **무엇이 들어 있어야:** 일반 유저, 헤비 유저, 매크로 봇, 작업장, 현금 거래(RMT) 계정이 섞여 있고, 현실에서 생기는 9가지 오염이 정해진 비율로 들어가 있어야 합니다.
4. **정답지:** 계정별 실제 유형과 오염 위치를 담은 정답지는 따로 보관했다가, 우리가 결과를 제출한 뒤에 받습니다. 대회처럼 채점합니다.

1 요청 배경과 목적

로그 워치독 팀은 게임 로그를 정제하고 매크로 봇 · 작업장 · 현금 거래 계정을 탐지하는 파이프라인과 대시보드를 3일 동안 만듭니다(1차 기획서). 실제 게임사 로그는 공개되지 않기 때문에, 현실적인 가상 로그가 필요합니다.

이 데이터에 필요한 조건은 세 가지입니다.

- **현실적이어야 합니다.** 시간대 분포, 유저 성향, 봇 행동이 실제 게임과 비슷해야 합니다. 무작위로 고르게 뿌린 데이터는 분석 결과가 의미 없어집니다.
- **지저분해야 합니다.** 현실 로그에서 생기는 오염이 정해진 비율로 들어가 있어야 정제 과정을 보여 줄 수 있습니다.
- **채점할 수 있어야 합니다.** 누가 봇인지, 어디에 오염을 넣었는지 정답을 기록해 두어야 우리 결과를 숫자로 평가할 수 있습니다.

데이터 팀에게도 좋은 포트폴리오가 됩니다. "실제 게임사 대회의 로그 구조와 봇 연구 통계를 근거로 설계한 합성 데이터 생성기"는 그 자체로 설명할 거리가 많은 결과물입니다. 참고할 실제 자료는 별첨 A와 별첨 B에 정리했습니다.

2 게임 세계 설정

두 팀이 같은 세계를 전제로 작업할 수 있도록 기본 설정을 정합니다. 세부 수치는 데이터 팀이 바꿔도 되지만, 바꾼 내용은 데이터 설명서에 적어 주세요.

항목	설정
서버	2개. KR1(한국 서버), GL1(글로벌 서버). 계정 비율 약 7:3
기간	28일 (예: 2026-09-01 ~ 2026-09-28)
패치	15일차 0시(UTC)에 클라이언트 v1.0 → v1.1 패치. 로그 컬럼 일부와 아이템 ID 일부가 바뀝니다(7장 참고)
맵	10개. 맵마다 좌표 범위(0~1000)와 적정 레벨 구간이 있음. 마을 맵 1~2개 포함
캐릭터	직업 4종(전사, 마법사, 궁수, 사제), 레벨 1~60, 계정당 캐릭터 1~3개
아이템	약 300종. 장비, 소모품, 재료, 잡템. 아이템마다 기준 시세(base_price)가 있음
재화	골드 1종. 보유 골드는 정수, 상한 2,147,483,647(32비트)

3 제공 테이블과 스키마

시각은 모두 ISO 8601 형식(2026-09-01T12:34:56.789Z)으로 기록합니다. 단, 7장의 타임존 오염은 예외입니다. ID는 아래 형식을 따라 주세요.

① events — 이벤트 로그 (핵심 테이블)

컬럼	타입	설명
event_id	string	이벤트 고유 ID. 예: E00000012345
event_ts	timestamp	클라이언트가 기록한 시각
server_ts	timestamp	서버가 받은 시각. 보통 event_ts보다 0~2초 늦음
server_id	string	KR1 또는 GL1
account_id	string	예: A000123
char_id	string	예: C0001234
session_id	string	로그인부터 로그아웃까지 하나의 세션
event_type	string	login, logout, move, kill, loot, levelup, death, revive, shop_buy, shop_sell, trade, chat, party_join, party_leave, guild_join, teleport, craft
map_id	string	예: M03
pos_x, pos_y	float	맵 안의 좌표

char_level	int	이벤트 시점의 캐릭터 레벨
item_id	string	관련 아이템 (loot, shop, trade, craft). 없으면 비움
qty	int	아이템 수량. **v1.1부터 컬럼명이 `quantity`로 바뀜**
gold_delta	long	이 이벤트로 늘거나 준 골드
target_id	string	상대 캐릭터 ID 또는 몬스터 ID (kill, trade, chat 등)
trade_id	string	event_type이 trade일 때 trades 테이블과 연결
ip	string	login 이벤트에 기록. 가상의 IP (예: `10.23.45.67`)
device_id	string	login 이벤트에 기록. 예: `D00321`
client_ver	string	`1.0` 또는 `1.1`
channel	int	**v1.1부터 새로 생긴 컬럼**. 채널 번호 1~10

이벤트 밀도: move는 60초에 한 번씩만 기록합니다. 사냥 중인 캐릭터는 시간당 40~80건 정도의 이벤트가 나오게 해 주세요. 이 기준이 전체 데이터 양을 결정합니다.

② trades — 거래 기록

컬럼	타입	설명
trade_id	string	예: `T0000123`
trade_ts	timestamp	거래 시각 (서버 기준)
server_id	string	서버
seller_char_id, buyer_char_id	string	판매자, 구매자 캐릭터
item_id, qty	string, int	거래한 아이템과 수량. 골드만 보내는 거래면 item_id를 비움
gold_amount	long	구매자가 판매자에게 준 골드
trade_type	string	`direct`(1:1 교환) 또는 `market`(거래소)

③ 기준 정보 테이블

테이블	컬럼
accounts	account_id, created_at, country, server_id
characters	char_id, account_id, class, created_at, server_id
item_master	item_id, legacy_item_id(패치 전 ID, 바뀐 아이템만), name, category, base_price, introduced_ver

map_master	map_id, name, x_min, x_max, y_min, y_max, min_level, max_level, is_town
staff_accounts	account_id, role(gm, test). 운영팀이 주는 화이트리스트라는 설정

4 유저 구성과 행동 규칙

비율은 실제 연구에서 확인된 봇 비율(12~16%, 별첨 A의 3장)을 기준으로 정했습니다. 계정 4,000개 기준 예상 인원도 함께 적었습니다.

유형	비율	계정 수	행동 규칙
일반 유저	72%	약 2,880	저녁 19~24시(KST)에 몰리고 주말에 30% 늘어남. 하루 1~3시간, 28일 중 40~70% 접속. 행동 간격이 불규칙(변동계수 0.8 이상). 여러 맵을 돌아다니고 채팅 · 파티 · 길드 활동이 있음. 레벨이 오를수록 성장이 느려짐.
헤비 유저	10%	약 400	하루 4~10시간, 거의 매일 접속, 빠른 성장. 행동량은 많지만 간격은 불규칙하고 소셜 활동이 활발함. **봇과 헷갈리게 만드는 것이 목적**입니다.
매크로 봇	10%	약 400	하루 18~24시간 접속. 행동 간격이 거의 일정(평균 2~4초, 변동계수 0.1 이하). 맵 1~2곳에서 같은 경로를 반복하며 사냥 · 줍기만 함. 채팅 · 파티는 거의 없음. 모은 아이템은 거래소에 주기적으로 판매.
작업장	6%	약 240	매크로 봇처럼 행동하되 **10~30개 계정이 한 그룹**(그룹 10~15개). 그룹마다 IP 1~3개와 기기 몇 대를 공유. 같은 날 몇 분 간격으로 생성된 계정들. 하루 1~2회 모은 골드를 RMT 허브로 보냄.
RMT 허브	0.3%	약 12	여러 작업장 계정에서 골드를 받고, RMT 구매자에게 나눠 줌. 사냥은 거의 하지 않음.
RMT 구매자	1.5%	약 60	평소엔 일반 유저처럼 행동하다가, 허브와 **시세와 동떨어진 거래**를 함(잡템 1개에 수백만 골드, 또는 고가 장비를 1골드에).
운영 · 테스트 계정	0.2%	약 8	텔레포트가 잦고, 맵 밖 좌표가 찍히고, 아이템을 대량으로 생성함. staff_accounts에 올라 있음.

비율과 수치는 권장값입니다. 데이터 팀이 더 현실적이라고 판단하면 바꿔도 되지만, 바꾼 값은 데이터 설명서와 정답지에 적어 주세요. 단, **헤비 유저는 꼭 넣어 주세요.** 실제 연구에서도 헤비 유저와 봇을 구분하는 것이 가장 어려운 문제였습니다(별첨 B-4).

5 데이터 양

포트폴리오로서 "수천만 건을 처리했다"고 말할 수 있으면서, 3일 안에 노트북 한 대로 처리할 수 있는 규모로 정했습니다.

구분	계정	캐릭터	기간	이벤트	거래	예상 용량	용도
샘플	200	약 300	1일	약 10만	약 2천	10MB 안팎	스키마 확인, 우리 팀 코드 뼈대 개발

최소	2,000	약 2,800	28일	약 1,200만~1,800만	약 10만	CSV.gz 0.6~1GB	일정이 빠듯할 때의 하한선
권장	**4,000**	**약 5,500**	**28일**	**약 2,500만~3,500만**	**약 20만~30만**	CSV.gz 1.2~2GB	**본 데이터**
확장	20,000	약 28,000	28일	1억 건 이상	100만 이상	5GB 이상	여유가 있을 때 별도 제공 (대용량 처리 시연용)

이벤트 수는 유저 구성과 이벤트 밀도에서 자연스럽게 정해집니다. 권장안 기준으로 하루 약 100만~120만 건이 나옵니다. 실제로 나온 건수를 데이터 설명서에 적어 주세요. 참고로 실제 아이온 봇 탐지 대회 데이터는 22일에 184GB였습니다(별첨 B-1).

6 현실감 요구사항

시간 분포

KST 저녁 피크, 새벽 3~7시 최저, 주말 증가. 봇은 시간대와 상관없이 고르게. 모든 시각이 균일하게 퍼져 있으면 안 됩니다.

성장 곡선

레벨이 오를수록 다음 레벨까지 필요한 시간이 늘어나게. 봇은 한 사냥터에 머물러 일정 레벨에서 정체.

경제

일반 거래 가격은 base_price ±20% 안. RMT 거래만 크게 벗어나게. 봇이 많이 줍는 아이템은 기간 동안 시세가 조금씩 내려가면 더 좋습니다.

관계

일반 유저끼리는 친구 · 파티 · 길드로 느슨하게 연결. 작업장은 그룹 안에서만 촘촘하게 연결되고 골드 흐름이 한 방향(→ 허브).

일관성

정상 데이터는 서로 맞아야 합니다. 예를 들어 trade 이벤트와 trades 테이블, 캐릭터의 서버와 이벤트의 서버, 레벨과 맵의 적정 레벨.

재현성

생성기에 난수 시드를 고정해서, 같은 시드로 돌리면 같은 데이터가 나오게 해 주세요.

7 오염 주입 명세

아래 9가지 오염을 정해진 비율로 넣어 주세요. **데이터 설명서에는 오염을 적지 말고**, 정답지의 오염 목록에만 기록합니다. 우리가 직접 찾아내야 하기 때문입니다.

#	오염	비율 · 범위	넣는 방법
1	중복 이벤트	이벤트의 1.5%	같은 event_id의 행을 한 번 더 기록. server_ts만 0~3초 뒤로
2	시간 역전	이벤트의 0.5%	event_ts를 1~600초 앞뒤로 틀어서 같은 캐릭터의 이벤트 순서가 뒤바뀌게. server_ts는 정상
3	타임존 혼재	KR1 서버 전체	KR1 서버는 시각을 KST(UTC+9)로, 시간대 표시 없이 기록. GL1은 UTC로 정상 기록
4	logout 누락	세션의 5%	세션 마지막 logout 이벤트를 빼기 (강제 종료 · 크래시 상황)
5	스키마 버전 혼재	패치 이후 전체	15일차부터 `qty` → `quantity`, `channel` 추가. 단, 패치 이후에도 클라이언트의 3%는 v1.0 형식으로 계속 기록
6	아이템 ID 변경	아이템 30종	패치 이후 30종의 ID를 새 번호로 바꿈. item_master의 legacy_item_id로 연결할 수 있게
7	골드 음수 · 오버플로	이벤트의 0.01%	loot인데 gold_delta가 음수, 또는 2,147,483,647을 넘는 값
8	운영 · 테스트 계정	계정 약 8개	4장의 운영 계정 행동. staff_accounts에는 올리되 events에는 일반 계정처럼 섞음
9	좌표 이탈	이벤트의 0.1%	map_master의 좌표 범위를 벗어난 pos_x, pos_y
+	형식 깨짐	행의 0.02%	CSV 행의 컬럼 수가 맞지 않거나, 숫자 칸에 문자, 빈 event_type. 격리 테이블로 보내는 대상

> 오염은 정상 데이터를 먼저 다 만든 뒤 마지막 단계에서 넣어 주세요. 그래야 정답지에 "원래 값"과 "바뀐 값"을 함께 남길 수 있습니다.

8 정답지

정답지는 본 데이터와 따로 보관했다가, 우리가 2일차 저녁까지 탐지 결과(`predictions.csv`)를 제출한 뒤에 전달해 주세요. 미리 보면 채점이 의미가 없어집니다.

파일	컬럼
labels.csv	account_id, actor_type(normal, heavy, macro_bot, workshop, rmt_hub, rmt_buyer, staff), group_id(작업장 그룹 번호, 해당 시)
contamination_manifest.csv	file, row_ref(event_id 또는 행 번호), contamination_type(1~9, +), column, original_value, injected_value
generation_summary.md	실제 생성된 건수, 유형별 계정 수, 오염별 건수, 사용한 시드와 파라미터

우리가 제출할 `predictions.csv`의 형식은 `account_id, predicted_type, risk_score, reason`입니다.

9 전달 형식

항목	요청
파일 형식	events는 날짜별 **CSV.gz** (실제 로그 파일처럼). 나머지 테이블은 CSV. 인코딩 UTF-8, 구분자 쉼표, 첫 줄 헤더
폴더 구조	`events/date=2026-09-01/events_KR1.csv.gz` 처럼 날짜 · 서버별로 나눔. `trades/`, `master/`, `README.md`
데이터 설명서	README.md에 테이블별 컬럼 설명, 건수, 세계 설정을 바꾼 내용. 오염은 적지 않음
전달 방법	Google Drive 공유 폴더 [링크 협의]. 파일마다 크기와 SHA-256 체크섬 목록을 함께
생성기 코드	프로젝트가 끝난 뒤 공유해 주면 좋습니다 (선택). 발표에서 두 팀의 협업 사례로 함께 소개할 수 있습니다

10 일정과 소통

시점	할 일	날짜
요청	이 요청서 전달, 질의응답	[협의]
샘플 전달	200계정 · 1일치 샘플. 우리 팀이 하루 안에 스키마를 확인하고 의견 전달	[협의]
스키마 확정	샘플 확인 뒤 스키마를 고정. 이후 변경은 두 팀이 합의할 때만	[협의]
본 데이터 전달	권장안 28일치. 우리 팀 3일 작업의 시작점	[협의] (= 우리 1일차 오전)
결과 제출	우리 팀이 predictions.csv 제출	우리 2일차 저녁
정답지 전달	labels, contamination_manifest, generation_summary	결과 제출 직후

- **소통 채널:** Discord 공용 채널 하나를 만들고, 질문과 답은 고정 메시지나 공유 문서에 쌓습니다.
- **질문 범위:** 우리 팀은 스키마와 형식에 대해서만 묻고, 오염 위치나 봇 계정은 묻지 않습니다.
- **담당자:** 각 팀에서 연락 담당 한 명씩 [이름].

11 검수 기준

본 데이터를 받으면 우리 팀이 아래 항목을 확인합니다. 통과하지 못한 항목은 바로 공유하겠습니다.

✓	항목	기준
☐	파일 무결성	체크섬 목록과 모두 일치
☐	스키마	3장의 컬럼명 · 타입과 일치 (의도된 v1.1 변경 제외)

☐	건수	계정 수 · 기간 · 이벤트 수가 합의한 규모 범위 안
☐	참조 무결성	events의 account_id · char_id · item_id · map_id가 기준 테이블에 있음 (의도된 오염 제외)
☐	시간 분포	시간대별 · 요일별 이벤트 수가 균일하지 않고 6장의 패턴을 보임
☐	거래 연결	trade 이벤트와 trades 테이블이 trade_id로 연결됨
☐	문서	README.md에 건수와 컬럼 설명이 있음

정답지를 받은 뒤에는 데이터 팀과 함께 "실제 넣은 오염 건수"와 "정답지 기록"이 맞는지도 한 번 맞춰 봅니다.

12 참고 자료

- 별첨 A · 실제 데이터 출처와 기업 공개 대회: 로그 구조(엔씨소프트 GDMC 2017, 빅콘테스트), 실제 봇 비율, 탐지 특징값
- 별첨 B · 출처별 원문 번역 정리: 특히 B-1(아이온 봇 데이터), B-4(헤비 유저와 봇), B-7(로그 스키마 77필드 구조), B-12(리니지 5개 테이블)
- 1차 · 팀 기획서: 이 데이터로 우리가 만들 것